Plan Harness Engineering — agent de lot

V8 Harnais généralisé (expérience LOT_011 G11 + LOT_012 G12, PR #436) · PROFILES 2023 · prompt en vigueur **PROMPT V8** (`PROMPT_Casern`) · vague inverse documentée **LOT_226** O7.4.

Document pour un lecteur qui ne connaît *rien* au harness (harnais logiciel qui entoure l'agent pour le rendre précis, puissant et économe en jetons). Police : Atkinson Hyperlegible. Date de lecture des sources : **25 octobre 2026, Europe/Zurich**.

Sommaire cliquable

1. E0 — Qu'est-ce qu'un harness ? (définition zéro jargon)
2. E1 — Les 4 pièces déjà disponibles chez Vial
3. E2 — Schéma mécanique d'un lot (nœuds cliquables)
4. E3 — Étape 1 Entrée du chapitre
5. E4 — Étape 2 Sites / sources
6. E5 — Étape 3 MCP mobilisés
7. E6 — Étape 4 Automates
8. E7 — Étape 5 Bracelet
9. E8 — Étape 6 Maximum du plan monographique V8 (14 points)
10. E9 — Contrats entrée/sortie des scripts
11. E10 — Fallback si un MCP tombe
12. E11 — Budget jetons du bracelet
13. E12 — Runbook solo d'un lot
14. E13 — Boucle de vérité, PROMPT V8, vague inverse
15. Sources
16. Top 5 IA vidéo
17. Prompt vidéo fonctionnelle du harnais

___FIRST_SECTION___ class="step s1" id="e0">

0 Qu'est-ce qu'un harness ?

Un **harness** (harnais) est l'ensemble des outils *autour* de l'agent (le bot qui rédige), pas l'agent lui-même. Sans harness, l'agent relit trop, invente, oublie, gaspille des jetons

(unités de calcul du modèle) et s'épuise. Avec harness, chaque étape a un **contrat** (règle écrite : ce qui entre, ce qui sort, ce qui est interdit).

Image simple. L'agent est le chirurgien. Le harness est la salle : check-lists, instruments stériles, chronomètre, alarme si un appareil tombe. Le chirurgien décide ; la salle empêche les erreurs répétables.

▸ **Pourquoi « engineering » (ingénierie) ?**

> Parce que chaque pièce a une **entrée** (INPUT), une **sortie** (OUTPUT), un échec prévu et un chemin de secours. Ce n'est pas une liste d'outils posés au hasard : c'est un circuit.

▸ **Objectif chiffré pour un lot**

> Un agent + son harness gère **seul un lot** (SSP + 10 DX) : recherche → Appel A → Parties B → audits → dépôt HTML 90–200 Ko, sans s'épuiser et sans inventer de dose.

1 Les 4 pièces déjà disponibles chez Vial

Le harness installé ici réutilise le matériel déjà en place (Thunder → Bitender → Grok Bot), sans inventer une stack nouvelle.

Script 1

Script 1 (outil déterministe d'extraction / budget) : lit un morceau ciblé d'un gros fichier, jamais le fichier entier. Chez Vial : `tools/arsenal/extrait.py` + `tools/budget.py`.

▾ **Contrat Script 1**

Script 2

Script 2 (outil déterministe d'assemblage / PR / CI) : injecte le lot, ouvre la PR, attend la CI. Chez Vial : `tools/arsenal/lot.py`, `pr.sh`, `ci_attente.sh`, `audit_diff.py`.

▾ **Contrat Script 2**

ENTRÉE (INPUT)
Identifiant SSP/DX ou chemin ; option partie N ; plafond de lignes.

SORTIE (OUTPUT)
Extrait compact (texte/JSON) + métadonnées ; code retour 0/≠0.

Interdit : renvoyer `app_v2.html` entier (~440 Ko).

ENTRÉE
Artefacts validés (JSON/HTML lot) + message PR + branche.

SORTIE
URL PR ; statut CI une ligne ; diff d'audit borné (--max).

MCP

MCP (Model Context Protocol = serveurs d'outils connectés que l'agent appelle sans quitter le chat) : Drive, GitHub/Origin, Calendar, etc. Ils apportent fichiers et actions externes.

▸ **Contrat d'un appel MCP**

ENTRÉE
Nom d'outil + arguments typés (fileId, query…).

SORTIE
JSON/texte utile OU erreur explicite → bascule fallback (§E10).

Automates

Automate (script déterministe sans LLM) : contrôles mécaniques (doses vs liste AIPS, sources datées, infobulles, chaîne lésion→PEC). Galien (revue clinique) ne lit que le diff + signalements.

▸ **Contrat automate**

ENTRÉE
Fichier HTML/JSON du lot + liste de règles.

SORTIE
Rapport pass/fail + liste d'anomalies ; zéro prose libre.

Bracelet

Bracelet (couche permanente d'optimisation jetons/outils, greffée à chaque session) : catalogue + script `bracelet_suggest.py` qui suggère l'outil avant crawl, gros volume, cache, mémoire, budget. Source : `/home/box/agent-data/bracelet/BRACELET_OPTIMISATION.md`.

▸ **Que contient le bracelet ? (5 familles)**

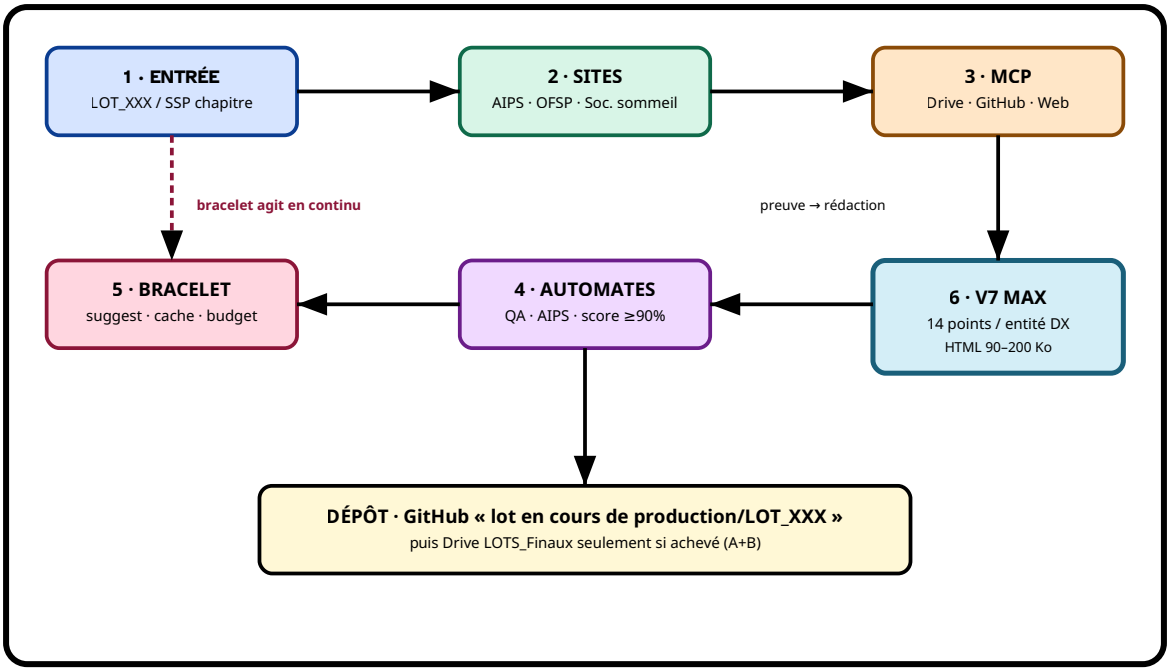
- **Filtrage** : Crawl4AI, Firecrawl, Chonkie, FlagEmbedding, LLMLingua, RTK
- **Mémoire** : Mem0, Graphiti
- **Cache** : GPTCache, Portkey, Prefect, requests-cache, Hishel
- **Orchestration** : APScheduler, Celery
- **Protection / route / observe** : PyBreaker, LiteLLM, RouteLLM, Semantic Router, Phoenix

Référence ARSENAL (20.10.2026) : `docs/ARSENAL.md` — interdits communs + pipelines Alpha/Beta/Gamma/Delta/Auditeur.

2 Schéma mécanique — parcours d'un chapitre (tout LOT_XXX)

1 Entrée | 2 Sites | 3 MCP | 4 Automate | 5 Bracelet | 6 Plan V7 max

Chaque rectangle du schéma est aussi une ancre cliquable ci-dessous. Survolez / ouvrez les ▸ **détails** sous le schéma pour l'explication sans surcharger le dessin.



▸ **Lire le schéma en une phrase**

> Le chapitre du lot assigné entre → le bracelet filtre et budgète → les sites suisses/europeens fournissent les preuves via MCP → les automates vérifient → le plan V7 à 14 points produit le HTML → dépôt GitHub tant que non achevé.

3 Étape 1 — Entrée du chapitre (INPUT du circuit)

Entrée = ce que l'agent reçoit avant d'écrire. Pour le lot assigné :

- Code PROFILES **G11** · titre officiel troubles du sommeil · n° lot **011**.
- Statut : **0/5 fichiers**, A 0/11, B 0/11 → dossier GitHub `lot en cours de production/LOT_XXX/`.
- Prompt absolu : **PROMPT_ULTIME V7** (22 oct. 2026) — lit avant toute ligne.
- Décision plan : monographie **applicable** à chaque entité (SSP + chaque DX). Si un DX transversal forçait un plaquage absurde → signaler plan alternatif (V7 §6.4).

▾ **Contrat d'entrée lot**

ENTRÉE
LOT_id, code SSP, titre, liste DX.1–10 (après Appel A), chemin evidence/, branche GitHub.

SORTIE de cette étape
Brief agent + fichier evidence vide prêt + confirmation « plan monographique OUI/SIGNALER ».

↑ schéma · → sites

4 Étape 2 — Sites / sources qui interviennent

Hiérarchie V7 (aucune donnée de mémoire) :

Rang	Site / organisme	Rôle pour le SSP du lot	Outil bracelet typique
1 CH	swissmedicinfo.ch (AIPS)	Doses hypnotiques / mélatonine / stimulants autorisés CH	Crawl4AI → Markdown propre
1 CH	OFSP / OFS / Obsan	Épidémiologie suisse sommeil / santé publique	Firecrawl champs ciblés
1 CH	Sociétés suisses (SSMIG…)	Recommandations cliniques CH si existantes	requests-cache + Hishel
1 CH	Tox Info Suisse / Fedlex	Surdosage hypnotiques ; cadre légal conduite	Crawl4AI
2 EU	ESR / guidelines européennes sommeil	Critères diagnostiques (si reconnus CH)	Chonkie + FlagEmbedding
3 INT	Seulement si reconnu en Suisse	Jamais AASM/FDA seule comme référence	—

▸ **Contrat « preuve » (evidence file)**

ENTRÉE
URL + date consultation Europe/Zurich + extrait lu dans UN seul document.

SORTIE
Ligne [S n] prête pour la section Sources du HTML ; dose uniquement si AIPS ouvert.

→ MCP

5 Étape 3 — MCP mobilisés (serveurs d'outils connectés)

MCP	Quand	ENTRÉE	SORTIE	Si panne →
user-Google-drive	Lire V7, déposer HTML achevé	fileId / folder	contenu ou lien	copie locale / workspace + dire l'échec
cursor-github / cursor-origin	Branche lot, PR	path, message	commit/ PR URL	diff local + patch fichier
WebSearch / WebFetch (ou navigateur box)	Ouvrir AIPS / guidelines	URL / query	texte page	Crawl4AI local / curl box
cursor.RecallMemory	Rappel profil harness	query	faits profil	relire BRACELET.md + ARSENAL.md

▸ **Pourquoi des MCP « contextuels » ?**

> On n'active que les serveurs utiles à la tâche (Drive pour dépôt, GitHub pour branche). Moins de bruit = moins de jetons = plus de précision.

→ automates

6 Étape 4 — Automates qui se déclenchent

Sans LLM. Exemples alignés ARSENAL + audit médical 2 tiers :

1. `extrait.py` / budget — empêche la lecture totale.
2. Contrôles déterministes posologie suisse (AIPS) — doses vs extrait.
3. Sources datées + présence des 14 points + balise `FIN_FICHIER`.
4. Taille fichier 90–200 Ko ; sinon découpe a/b.
5. `audit_diff.py` — l'auditeur ne relit que le diff.

6. Score V7 §6.3 ≥ 90 % et zéro critique avant dépôt.

▼ **Contrat automate « gate dépôt »**

ENTRÉE
HTML candidat + rapport questions 6.1.

SORTIE
`ALLOW_DEPOSIT=yes|no` + liste FAIL. Si no → retour rédacteur, pas Drive Finaux.

→ **bracelet**

7 Étape 5 — Où le bracelet agit

Le bracelet est **permanent** : consulté *avant* chaque optimisation, appel externe, volume, répétition.

Moment du lot	Suggestion bracelet	Effet
Avant d'ouvrir AIPS	Crawl4AI / Firecrawl	Markdown propre, menus retirés
Guideline longue	Chonkie + FlagEmbedding + LLMLingua	Chunks + rerank + compression
Reprise session	Mem0 / Graphiti	Faits lot sans rejouer l'historique
Même URL déjà vue	GPTCache / Hishel / requests-cache	Zéro re-téléchargement
Tâche simple (renommer, lister)	RouteLLM / Semantic Router	Modèle cheap
API qui échoue en boucle	PyBreaker	Pause + fallback
Suivi coût	LiteLLM + Phoenix	Budget + traces

Commande : `python3 /home/box/agent-data/bracelet/bracelet_suggest.py "…tâche…"`

▶ **Contrat bracelet_suggest**

ENTRÉE
Phrase de tâche (texte libre).

SORTIE
Top N outils {category, name, repo, use, score}.

→ plan V7 max · budget jetons

8 Étape 6 — Maximum du plan monographique V8 (14 points)

C'est le **point de maximisation** : ici le harness sert la qualité clinique, pas seulement l'économie. Chaque monographie (SSP G11 *et* chaque DX) porte les 14 points. Aucun point manquant.

#	Point V8	Composant harness qui maximise	Check monographie (SSP du lot)
1	Définition et sémantique	Evidence MCP + fenêtres <details>	Insomnie vs hypersomnie vs parasomnie distinguées
2	Épidémiologie CH→EU	OFSP/OFS via Crawl+cache	Chiffres sourcés datés seulement
3	Physiopathologie + tableau lésion→expl→ttt	Automate présence tableau	Mécanismes éveil/sommeil NREM-REM
4	Démarche diagnostique	Appel A liste DX	Graves d'abord (narcolepsie, SAOS…)
5	Anamnèse + drapeaux rouges	Checklist automate	Stop respiratoire, cataplexie, etc.
6	Examen physique	Fenêtres technique	Normal avant pathologique
7	Approche syndromique	Automate signes définis	Syndromes éclatés SF/SP
8	Diagnostic positif	Source société+année	Critères nommés ; ce qui ne suffit pas
9	Examens (gold / 1re / 2e)	Tableaux interprétation	PSG, MLST, oxymétrie…

#	Point V8	Composant harness qui maximise	Check monographie (SSP du lot)
10	Arbre décisionnel	Cohérence A ↔ B	Embranchements signés
11	PEC A-B-C-D + situations spéciales	AIPS only + audit médical	Grossesse, sujet âgé, IH/IR
12	Prévention 3 niveaux	Sources CH	Hygiène sommeil, dépistage SAOS
13	Points clés 3–6 phrases	Style verbal V7 §7	Zéro liste télégraphique
14	Pièges examen fédéral	Auditeur linguistique	Confusions classiques + bonne réponse

▸ **Cadence fichiers V7 (rappel)**

> 5 HTML : Appel A (SSP+liste DX) ; B P1 DX1–2 ; P2 DX3–5 ; P3 DX6–7 ; P4 DX8–10. 4 agents : 2 rédacteurs + auditeur médical + auditeur linguistique. Score ≥90 %.

Si le plan monographique ne s'applique pas à une entité : l'agent le signale en une phrase et propose un plan exhaustif alternatif (V7 §6.4 classe `plan-academique`) — règle owner 25.10.2026.

→ contrats scripts

9 Critique 1 — Contrats d'entrée/sortie documentés (scripts)

Script	ENTRÉE	SORTIE	Échec	Interdit
Script 1 `extrait.py`	`ssp|mono|region` + id + options	extrait borné	code ≠0 + message	fichier entier
Script 1b `budget.py`	fichier + --lignes	OK/DEPASSÉ	DEPASSÉ	ignorer le plafond

Script	ENTRÉE	SORTIE	Échec	Interdit
Script 2 `lot.py`	type + clé + payload	artefact prêt PR	validation schema fail	dose sans AIPS
Script 2b `pr.sh` + `ci_attente.sh`	titre + paths	URL PR + CI résumé 1 ligne	CI rouge → stop merge	merge sans CI
Script 2c `audit_diff.py`	PR + --max	valeurs modifiées + sources	diff trop large	auditer sa propre prose
Bracelet `bracelet_suggest.py`	tâche texte	top outils JSON/texte	catalogue manquant	sauter la suggestion sur gros fetch

10 Critique 2 — Fallback si un MCP tombe

Panne	Symptôme	Fallback immédiat	Ce qu'on dit à Vial
Drive MCP	timeout / 403	Fichier dans `/workspace/` + lien GitHub	« Drive inaccessible ; livré localement »
GitHub MCP	auth / rate limit	git CLI local si dispo, sinon patch fichiers	état exact, pas de faux dépôt
WebFetch bloqué	403 provider	navigateur box ou curl (public) ; Crawl4AI	source quand même ouverte
AIPS down	page vide	marquer « À vérifier (AIPS) » + HELP ; ne jamais inventer	question HELP formatée
MCP boucle d'erreur	retries	PyBreaker open → stop retries	une seule alerte claire

Règle V7 §1 : ne jamais affirmer un dépôt non fait ; ne jamais contourner un filtre de sécurité.

11 Critique 3 — Budget jetons propre au bracelet

Le bracelet a son **enveloppe** séparée du budget rédaction, pour ne pas manger la monographie.

Poste bracelet	Plafond indicatif / lot	Compteur	Action si dépassement
Suggestions + routage	≤ 2 % jetons lot	LiteLLM tag `bracelet.route`	figer top-3 outils du catalogue
Compression / rerank	≤ 8 %	`bracelet.compress`	Chonkie seul, skip LLMLingua
Mémoire retrieve	≤ 3 %	`bracelet.mem`	Mem0 top-k=3 max
Cache miss HTTP	hors LLM (réseau)	Hishel hit-ratio	cible hit ≥ 60 % après 1er passage
Traces Phoenix	≤ 1 %	échantillon	échantillonner 1/10 appels
Total bracelet	**≤ 15 % du lot**	dashboard	mode survie : Script1+cache+AIPS only

▸ **Mode survie (anti-épuisement)**

> Si budget bracelet > 15 % ou agent fatigué : (1) stop RouteLLM expérimental, (2) une source CH à la fois, (3) une monographie à la fois (V8 §11), (4) automates only avant nouvel appel LLM.

12 Runbook solo — agent gère un lot seul

1. Lire V8 entier + ARSENAL + bracelet_suggest « LOT_XXX evidence SSP ».
2. Créer `lot en cours de production/LOT_XXX/` + `evidence/`.
3. Collecter preuves CH→EU (MCP/Web + Crawl4AI) ; zéro rédaction.
4. Rédiger Appel A (14 points SSP + 10 DX) → double audit → score ≥90 %.

5. Parallèle : P1–P2 et P3–P4 (cadence 2-3-2-3) ; chaque fichier audité.
6. Automates gate → HTML 90–200 Ko + FIN_FICHIER.
7. Tant que B < 11/11 : reste sur GitHub. Si A+B complets : Drive **LOTS_Finaux avec statut** (text/html sans conversion) + retirer de « lot en cours ».
8. Chat : une phrase verbale + liens (règle synthèse owner).

Organisation fichiers LOT_XXX (cible)

```
lot en cours de production/LOT_XXX/
  evidence/S01_….md
  LOT_011_Appel_A_V7_Plan_et_Liste.html
  LOT_011_Appel_B_V7_Partie_1_DX.1_a_DX.2.html
  LOT_011_Appel_B_V7_Partie_2_DX.3_a_DX.5.html
  LOT_011_Appel_B_V7_Partie_3_DX.6_a_DX.7.html
  LOT_011_Appel_B_V7_Partie_4_DX.8_a_DX.10.html
  AUDIT_*.md
```

Carte V7 (exigences §0–§14) → pièce du harness

§ V7	Exigence	Pièce
0	Posture clinicien / non-complaisance	Prompt système + audit
1	Honnêteté des actes	Fallback MCP + bilans exacts
2	Sortie HTML5 90–200 Ko	Automate taille + Script2 dépôt
3	Référentiel PROFILES 248	Entrée lot (E3)
4	Sources CH→EU, AIPS	Sites + bracelet crawl/cache
5	5 fichiers, 4 agents	Runbook + CI
6	14 points + score 6.3	Maximisation E8 + automates
7	Style verbal concis	Auditeur linguistique
8	Fenêtres <details>	Gabarit HTML
9	10 DX ordonnés	Appel A + cohérence
10	Gabarit technique	Automate HTML

§ V7	Exigence	Pièce
11	Anti-troncature	Une mono à la fois
12	Double audit	Agents distincts + audit_diff
13	Drive hygiène	MCP Drive + Finaux si achevé
14	Interdits	Gates automates

Glossaire express (toujours répétable)

- **Agent** : bot qui rédige/audite.
- **Harness** : harnais d'outils autour de l'agent.
- **Jeton** : unité de coût du modèle.
- **Script 1 / 2** : programmes locaux déterministes (extrait vs assemblage/PR).
- **MCP** : serveurs d'outils connectés.
- **Automate** : script sans LLM.
- **Bracelet** : couche permanente d'optimisation.
- **Contrat** : ENTRÉE / SORTIE / échec / interdit écrits.
- **SSP** : situation de départ PROFILES.
- **DX** : diagnostic différentiel monographie.
- **AIPS** : information professionnelle suisse (swissmedicinfo.ch).

13 Boucle de vérité + PROMPT V8 + vague inverse (2026-10-25)

Boucle de vérité (permanente). Avant chaque pas non trivial : (1) harnais en place ? (2) je le respecte ? Sans `PREUVE_EMBOITEMENT.txt` crédible (sortie locale de `bracelet_suggest.py` + ARSENAL lu), pas de production.

- **PROMPT V8** : dossier `PROMPT_Casern/` (GitHub + Drive Finaux). L'agent demande au démarrage si V8 est le prompt en vigueur.

- **Pipeline** : bracelet_suggest → Chonkie 1.6, LLMLingua 1.3, GPTCache 1.3 (PR #436 sur main).
- **Lieu** : brouillon GitHub `lot en cours de production/LOT_XXX/` ; Drive *LOTS_Finaux avec statut* seulement si Appel A+B validés ; pas de `lots-acheves` sur GitHub.
- **Vague inverse** 248→001 : premier lot entièrement vide documenté = **LOT_226** O7.4 (A 0/11 · B 0/11).
- **Silence owner** : blockers critiques → Grok Bot uniquement.
- **R15** : puces Automates actifs = workflows/outils CI seulement — jamais lister `harnais/*`.
- **Crédibilité PREUVE** : la sortie collée doit matcher un run local réel du bracelet (pas un texte inventé).

Signé : Grok Bot — 2026-10-25 Europe/Zurich — PROMPT_Casern / organigramme-examen-federal

---

Sources (lues 25.10.2026 Europe/Zurich)

1. [S1] PROMPT_ULTIME_PRODUCTION_LOTS_V7.md — Drive id `1t2zj4EWw3N7vmT1AQ9BB5pIfgA80J0-i` — V7 22.10.2026 — **lien**
2. [S2] PROMPT_ULTIME_PRODUCTION_LOTS_V7.pdf — Drive id `1IVUuKsyMm19zXJJV_DAEdPINlvHFqIRn`
3. [S3] BRACELET_OPTIMISATION.md — `/home/box/agent-data/bracelet/BRACELET_OPTIMISATION.md` + catalog.json + bracelet_suggest.py
4. [S4] ARSENAL.md — `/workspace/oe-arsenal/docs/ARSENAL.md` (et copies org-exam) — 20.10.2026
5. [S5] Statut LOT_011 — `/workspace/STATUT_LOTS_001_248.csv` + cumul BASE_LOTS — G11 à rédiger 0/5
6. [S6] Structure owner 25.10.2026 — GitHub `lot en cours de production/` ; Drive LOTS_Finaux = achevés seulement
7. [S7] Atkinson Hyperlegible — Google Fonts OFL — fichiers dans `/workspace/plan_harness_assets/`
8. [S8] PROFILES 2023 SSP — smifk-cims.ch/profiles-2023/ssps (référentiel V7 §3)

Contenu produit par IA à partir des sources citées ; non validé cliniquement par un médecin. Ceci est un **plan d'ingénierie**, pas un cours médical G11.

↑ **Sommaire**

Annexe — Checklist questions V7 §6.1 appliquée à G11

Chaque question doit recevoir 2 / 1 / 0 / sans objet avant dépôt. Automate d'audit linguistique/médical s'en sert.

▸ Point 1 Définition

- Définition précise société savante ? — *preuve / automate / fenêtre*
- 1–4 phrases + richesse fenêtres ? — *preuve / automate / fenêtre*
- Insomnie/hypersomnie/parasomnie distinguées ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ Point 2 Épidémiologie

- Distribution population CH ? — *preuve / automate / fenêtre*
- Histoire naturelle individu ? — *preuve / automate / fenêtre*
- Enjeux coût/gravité ? — *preuve / automate / fenêtre*
- Chiffres utiles sourcés seulement ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ Point 3 Physio

- Amorce→maintien compréhensible ? — *preuve / automate / fenêtre*
- Mécanismes→complications ? — *preuve / automate / fenêtre*
- Cibles thérapeutiques nommées ? — *preuve / automate / fenêtre*
- Tableau lésion→expl→ttt ? — *preuve / automate / fenêtre*
- Concis ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.

- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à ∅.

▸ **Point 4 Démarche**

- Graves avant fréquents ? — *preuve / automate / fenêtre*
- Chaque DD dangereux a signe qui tranche + piège ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à ∅.

▸ **Point 5 Anamnèse**

- Chaque question a raison physio ? — *preuve / automate / fenêtre*
- Drapeaux rouges actionnables ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à ∅.

▸ **Point 6 Examen**

- Normal avant pathologique ? — *preuve / automate / fenêtre*
- Technique + valeur diag par signe ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à ∅.

▸ **Point 7 Syndromique**

- Syndromes énumérés ? — *preuve / automate / fenêtre*
- SF vs SP éclatés ? — *preuve / automate / fenêtre*
- Chaque signe défini ? — *preuve / automate / fenêtre*

- Comment rechercher ? — *preuve / automate / fenêtre*
- Relié au mécanisme ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 8 Diag positif**

- Critères société+année clairs ? — *preuve / automate / fenêtre*
- Ce qui ne suffit pas dit ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 9 Explorations**

- Gold standard oui/non ? — *preuve / automate / fenêtre*
- 1re/2e intention + critère passage ? — *preuve / automate / fenêtre*
- Prescription comme la société ? — *preuve / automate / fenêtre*
- Tableau interprétation ? — *preuve / automate / fenêtre*
- Cas de figure résultats ? — *preuve / automate / fenêtre*
- Alternatives grossesse/enfant/DFGe/allergie/pacemaker ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 10 Arbre**

- Chaque branche signe→décision ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.

- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 11 PEC**

- But chiffré ? — *preuve / automate / fenêtre*
- Ordre et pourquoi ? — *preuve / automate / fenêtre*
- Urgences chronologiques ? — *preuve / automate / fenêtre*
- Mesures générales ? — *preuve / automate / fenêtre*
- Pharma complète AIPS ? — *preuve / automate / fenêtre*
- Non médicamenteux ? — *preuve / automate / fenêtre*
- Social/pro ? — *preuve / automate / fenêtre*
- Situations spéciales ? — *preuve / automate / fenêtre*
- Surveillance ? — *preuve / automate / fenêtre*
- Critères sortie ? — *preuve / automate / fenêtre*
- Pronostic 2026 ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 12 Prévention**

- 3 niveaux avec reco CH ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 13 Points clés**

- 3–6 phrases suffisent ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

▸ **Point 14 Pièges**

- Pièges EF + bonne réponse ? — *preuve / automate / fenêtre*
- **Application G11 :** vérifier que la réponse reste verbale, sourcée CH→EU, et que le bracelet a compressé les guidelines avant lecture agent.
- **Contrat point :** ENTRÉE = extrait evidence [Sn] ; SORTIE = bloc HTML du point + fenêtres ; ÉCHEC = question §6.1 à 0.

Matrice I/O complète des briques

Brique	ENTRÉE	SORTIE	SLA	Observabilité
Crawl4AI	URL + sélecteur	Markdown propre	<30s	Phoenix span crawl
Firecrawl	URL + fields	JSON/MD champs	<45s	cache Hishel
Chonkie	texte long	chunks	local CPU	n_chunks
FlagEmbedding	chunks + query	top-k rerank	local	k, scores
LLMLingua	prompt long	prompt compressé	budget compress	ratio tokens
RTK	stdout commande	stdout compressé	local	bytes saved
Mem0	fait + user/lot	retrieve faits	<1s	hit/miss
Graphiti	événement	graphe MAJ	async	nodes added
GPTCache	requête	réponse cache	<50ms	similarity
Portkey	requête gateway	réponse	SLA API	cache header
Prefect	task + inputs	result cache	workflow	skip count
requests-cache	HTTP GET	body + expiry	local	expiry
Hishel	HTTP	revalidé	local	304 ratio
APScheduler	cron	job id	process	last_run
Celery	queue payload	task id	broker	retries
PyBreaker	appel externe	ok ou reject	fail-fast	state open/closed

Brique	ENTRÉE	SORTIE	SLA	Observabilité
LiteLLM	model+messages	completion + cost	budget	$/tag
RouteLLM	prompt	model id	local router	%cheap
Semantic Router	utterance	route name	local emb	confidence
Phoenix	traces	UI/metrics	side	export
extrait.py	ssp/mono id	extrait	local	lines
lot.py	payload	artefact	local	schema
pr.sh	paths	PR URL	gh	number
ci_attente.sh	PR	pass/fail 1 ligne	CI	elapsed
audit_diff.py	PR	diff borné	local	n_hunks
bracelet_suggest.py	tâche	top outils	local	scores

Récit guidé — un chapitre DX de LOT_011 dans le harness

1. L'agent ouvre le brief LOT_011 et confirme : plan monographique applicable.
2. Il lance bracelet_suggest : Crawl4AI + GPTCache + LiteLLM remontent.
3. Il crée evidence/ et note l'horloge Europe/Zurich.
4. MCP WebFetch vers swissmedicinfo échoue 403 provider → fallback curl box + Crawl4AI.
5. Il extrait la posologie d'un hypnotique autorisé CH ; numéro Swissmedic lu à 5 chiffres sur la page, jamais depuis l'URL.
6. Mem0 stocke : « LOT_011 / molécule X / AIPS lu le 2026-10-25 ».
7. Il rédige le point 11 du DX dans un HTML Partie ; phrases verbales ; fenêtres détails.
8. Automate poseologie signale OK ; automate 14-points signale point 7 incomplet → réécriture.
9. Auditeur médical distinct vérifie AIPS ; auditeur linguistique vérifie style.
10. Score 6.3 = 92 % → ALLOW_DEPOSIT ; fichier reste sur GitHub car lot non achevé.
11. Chat owner : une phrase + lien fichier.

Responsabilités par fichier V7 pour LOT_011

Fichier	Contenu	Règle
Appel A	Monographie SSP G11 14 points + liste DX1–10 + tableau comparatif + algo	Fixe la loi du lot ; aucune Partie avant double audit A

Fichier	Contenu	Règle
B Partie 1	DX.1 et DX.2 monographies complètes	Rédacteur 1
B Partie 2	DX.3 à DX.5	Rédacteur 1
B Partie 3	DX.6 et DX.7	Rédacteur 2 parallèle
B Partie 4	DX.8 à DX.10	Rédacteur 2

Anti-patterns (ce que le harness empêche)

Anti-pattern	Sans harness	Avec harness
Lire app_v2 entier	440 Ko dans le contexte	extrait.py + budget.py
Dose de mémoire	erreur patient	AIPS only + automate
MCP en boucle	jetons brûlés	PyBreaker + message unique
Dépôt non audité	dette clinique	gate score ≥90 %
Drive = brouillon non fini	Finaux pollués	GitHub en cours only
Phrase nominale	style V7 cassé	auditeur linguistique
Guideline US seule	non conforme V7	filtre sources CH→EU
Relire PR entière	épuisement auditeur	audit_diff --max

Installation du harness sur le matériel déjà là

1. Vérifier `/home/box/agent-data/bracelet/` (MD + suggest.py + catalog.json).
2. Vérifier `docs/ARSENAL.md` et `tools/arsenal/` dans le clone organigramme.
3. Exporter variable `HARNESS_BRACELET_BUDGET_PCT=15`.
4. Avant chaque grosse tâche : `bracelet_suggest.py` → noter top 3 dans le journal du lot.
5. Brancher PyBreaker autour des appels MCP Web/Drive.
6. Activer requests-cache/Hishel pour AIPS et guidelines.
7. Pipeline CI : test_arsenal + lot.py auto + contrôles taille HTML.
8. Documenter les contrats I/O dans `docs/HARNESS_CONTRACTS.md` (ce plan en est la source).

Exemples d’entités DX (illustratif — à valider evidence)

Liste non définitive : l’Appel A sourcé fixera les 10 DX. Le harness impose le même plan 14 points à chacune.

- **Insomnie chronique — maximisation V7**

  > ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- **Syndrome d’apnées obstructives du sommeil (SAOS) — maximisation V7**

  > ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- **Narcolepsie — maximisation V7**

  > ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- **Syndrome des jambes sans repos — maximisation V7**

  > ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- **Parasomnie NREM (terreurs/éveils confusionnels) — maximisation V7**

  > ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- **Parasomnie REM (trouble comportemental) — maximisation V7**

  > ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- ▸ **Hypersomnie idiopathique — maximisation V7**

  ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- ▸ **Trouble du rythme circadien — maximisation V7**

  ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- ▸ **Insomnie secondaire médicamenteuse/toxique — maximisation V7**

  ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

- ▸ **Hypersomnolence liée à privation/hygiène — maximisation V7**

  ENTRÉE evidence spécifique → 14 points → automates AIPS/signes → SORTIE HTML mono dans la Partie adéquate. Bracelet : compresser reco sommeil avant rédaction point 9–11.

FAQ harness (cliquable)

▸ **Le harness remplace-t-il l'agent ?**

Réponse courte : Non. Il contraint et outille l'agent.

Le harness ne diagnostique pas et n'écrit pas la physiopathologie à la place du clinicien-agent. Il garantit que chaque phrase clinique reste attachée à une source ouverte, que les fichiers respectent 90–200 Ko, et que les outils coûteux ne tournent pas en boucle. L'agent reste responsable du fond ; le harness est responsable du circuit.

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ **Puis-je sauter le bracelet ?**

Réponse courte : Non sur fetch volumineux ; oui sur rename trivial.

Sur une tâche triviale (renommer un dossier, lire un CSV de 20 lignes), oui. Dès qu'il y a crawl, PDF long, guideline, ou répétition, non : lancez bracelet_suggest et appliquez au moins un outil de filtrage ou de cache. C'est la règle « permanent » du MD bracelet.

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ **Où vivent les lots non finis ?**

Réponse courte : GitHub « lot en cours de production/ ».

Décision owner 25.10.2026 : racine GitHub visible « lot en cours de production/ LOT_xxx/ ». Pas de lots-acheves sur GitHub. Cela évite les chemins profonds flash/ vague1/...

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ **Où vivent les lots finis ?**

Réponse courte : Drive LOTS_Finaux avec statut uniquement.

Uniquement Drive « LOTS_Finaux avec statut ». Audité ou non, dès que A+B sont complets (11+11 chapitres), le lot quitte GitHub en-cours pour Finaux.

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ **Que faire si V7 et ARSENAL divergent ?**

Réponse courte : V7 prime sur le contenu lot ; ARSENAL prime sur l'économie de jetons outils.

Pour le contenu médical et le format HTML, V7 gagne. Pour la manière d'ouvrir les fichiers du repo app et d'économiser les jetons d'ingénierie, ARSENAL gagne. Le bracelet s'applique aux deux.

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ Comment savoir qu'un contrat est respecté ?

Réponse courte : Sortie machine-lisible + code retour + log une ligne.

Chaque script doit pouvoir être appelé en CI. Si la SORTIE n'est pas parsable ou si le code retour est non nul, le gate dépôt reste fermé. Les contrats de ce plan sont la spécification.

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ Qu'est-ce qu'un jeton ?

Réponse courte : Unité de coût d'entrée/sortie du modèle.

Quand l'agent lit ou écrit du texte, le fournisseur de modèle compte des jetons. Moins on recolle de bruit (menus web, logs, fichiers entiers), plus on garde du budget pour la monographie utile.

ENTRÉE de la question : doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

▸ Pourquoi Atkinson Hyperlegible ?

Réponse courte : Police haute lisibilité (Braille Institute / OFL), contraste et dyslexie-friendly.

> Demandée par l'owner pour la clarté visuelle du plan. Les TTF OFL sont dans plan_harness_assets/ et chargées en @font-face.
>
> **ENTRÉE de la question :** doute opérateur. **SORTIE :** règle opératoire une phrase + lien interne.

Micro-contrats des flèches du schéma

- ▸ **Flèche 1→2**

  > ENTRÉE : Brief lot → liste d'URL à ouvrir. SORTIE : checklist evidence. Échec : stop et message owner une phrase.

- ▸ **Flèche 2→3**

  > ENTRÉE : URL validées → appels MCP/fetch. SORTIE : documents bruts. Échec : stop et message owner une phrase.

- ▸ **Flèche 3→4**

  > ENTRÉE : Documents → automates de conformité. SORTIE : rapport pass/fail. Échec : stop et message owner une phrase.

- ▸ **Flèche 5‖1..6**

  > ENTRÉE : Bracelet observe chaque flèche. SORTIE : suggestion outil + budget. Échec : stop et message owner une phrase.

- ▸ **Flèche 4→6**

  > ENTRÉE : Pass automates → rédaction 14 points. SORTIE : HTML mono. Échec : stop et message owner une phrase.

- ▸ **Flèche 6→dépôt**

  > ENTRÉE : HTML scorés → GitHub en cours. SORTIE : chemins fichiers. Échec : stop et message owner une phrase.

Top 5 IA vidéo moins chères, haute qualité (octobre 2026)

Sources vérifiées le 25.10.2026 (Europe/Zurich) : pages tarifaires / docs agrégées (llms.blog 19.10.2026, Kling membership, Google AI plans, Pika, Hailuo, xAI docs, X Subscription). Prix en USD hors taxes ; confirmer sur le site avant paiement. **Sora** : produit arrêté (avril 2026). Luma Plus démarre à 30 $/mois — hors top 5 « moins cher ».

▼ **Recommandation owner (usage occasionnel, budget serré)**

> **Choix n°1 :** *Google AI Plus* à **4,99 $/mois** — entrée la moins chère vers Veo / Omni Flash (qualité très haute pour le prix). Idéal pour tester le prompt harness en quelques clips.
>
> **Choix n°2 (qualité motion / 1080p commercial) :** *Kling Standard* — **6,99 $ le 1er mois**, puis **8,80 $/mois** (660 crédits). Prendre le 1er mois puis annuler si un seul film.
>
> **Sans abonnement (payer à la seconde) :** *Grok Imagine Video 1.5 Lite* (API xAI) — **0,03 $/s en 720p** (~4,50 $ pour 150 s). Ou Imagine via *X Subscription Premium* à 30 $/mois si tu veux aussi Grok/Cursor/X.

#	Outil	Abonnement le plus bas	Inclus (durée / résolution / volume)	Score qualité
1	**Google AI Plus** (Veo 3.1 / Gemini Omni Flash via Flow)	**4,99 $/mois** (US)	200 crédits Flow / mois + 50 crédits/jour ; Omni Flash ~720p (ex. 8 s ≈ 12 crédits) ; Veo 3.1 Fast ≈ 20 crédits / clip 8 s ; Veo Quality ≈ 100 crédits / 8 s — soit ~10 clips Fast ou 2 Quality avec les crédits mensuels seuls	**9/10** (modèle Veo top-tier ; volume limité)
2	**Kling AI Standard** (Kling 3.0 / 4.0)	**6,99 $** (1er mois) puis **8,80 $/mois** ; annuel ≈ 6,60 $/mois	660 crédits / mois ; 1080p/ 4K listés ; sans filigrane ; usage commercial listé sur les plans payants — ordre de grandeur ~40–50 s utiles selon modèle/audio	**9/10** (motion / personnages souvent excellents)

#	Outil	Abonnement le plus bas	Inclus (durée / résolution / volume)	Score qualité
3	**Pika Starter**	**10 $/mois** (8 $/mois en annuel)	900 crédits / mois ; sans filigrane ; *pas* de licence commerciale (Creator à 35 $) ; ~7 clips Seedance 2.5 5 s 720p selon estimation Pika	**7,5/10** (bon créatif social ; commercial = plan supérieur)
4	**Hailuo / MiniMax Standard**	**~10,50 $/mois** (≈ 8,40 $/mois annuel ; listé parfois « from 9,99 $ »)	~1 000 crédits / mois ; ~140 s MiniMax H3 768p ou ~80 s en 2K ; accès aussi à d'autres modèles selon page	**8/10** (bon rapport volume / prix ; 2K possible)
5	**Grok Imagine** (xAI) — abonnement *ou* API	**X Subscription Premium 30 $/mois** (vidéo Imagine dans le pool) ; sinon API sans abo : Lite **0,02–0,03 $/s** (480p/720p), 1.5 natif 1080p **0,25 $/s**	Clips 1–15 s ; 480p/720p/1080p ; audio + lip-sync ; Premium = pool d'usage partagé Grok/Cursor (renouvellement hebdo). Plus (8 $) = images Imagine, pas la vidéo	**8,5/10** (très bon pour schéma/voix ; Lite = meilleur $/s API)

▸ **Hors top 5 mais utiles (référence)**

- **Runway Standard** — 15 $/mois, 625 crédits ≈ 52 s Gen-4.5 — score qualité **9,5/10** mais cher à la seconde (~0,29 $/s).
- **Google AI Pro** — 19,99 $/mois, 1 000 crédits Flow — meilleur volume Veo/Omni pour un usage hebdo (score valeur **9/10**).
- **Luma Plus** — 30 $/mois, 10 000 crédits — commercial explicite ; trop cher pour « moins cher ».
- **Sora** — discontinué (2026) : ne pas choisir.

↑ Sommaire · ↓ Prompt vidéo · ancre `#top5-ia-video`

Prompt pour création d’une vidéo fonctionnelle du harnais

Bloc prêt à coller dans une IA vidéo spécialisée. Il décrit de façon métacognitive un agent qui travaille **avec** son harness autour de lui, sur le parcours concret **LOT_011 / G11 — Troubles du sommeil**.

↑ **Sommaire** · ancre `#prompt-video`

Prompt (sélectionner tout → copier) :

```
Crée une vidéo fonctionnelle, claire et pédagogique (2 à 4 minutes), style
```